

DRAFT PROPOSAL: StokLens

STATUS: DRAFT UNTUK DITINJAU. Belum siap dikirim.

Yang masih harus dibereskan sebelum submit:

- Isi angka uji lapangan di §6 dan §7 (bertanda ●). Jangan dikarang.
- Periksa ulang tidak ada jejak institusi: nama kampus, email kampus, logo, template. Termasuk nama folder yang terlihat di tangkapan layar.
- Batas **20 halaman** di luar cover, daftar pustaka, dan lampiran. Versi ini 15 halaman badan + 1 halaman lampiran.
- Cek plagiarisme.

1. Nama Tim dan Judul Proyek

Nama tim: The Goyzalis 2.0

Judul: StokLens, Stock Opname Otomatis Berbasis Visi Komputer untuk Warung dan Toko Kelontong

Anggota: Marshal Rizky Raditya · Danish Ahmad Satria · Nicolas Nathan Abimanyu · Muhammad Bhre Zidane Pribadi · Muhammad Noby Ghazali

Tema: Smart Logistics

2. Latar Belakang

2.1 Masalah

Warung Madura dan toko kelontong kecil menyimpan ratusan SKU dalam ruang sempit, tetapi hampir tidak pernah melakukan stock opname. Alasannya bukan kemalasan, melainkan biaya: menghitung manual satu warung memakan waktu berjam-jam dan harus dilakukan saat toko tutup. Akibatnya pemilik tidak pernah tahu dua angka yang menentukan kelangsungan usahanya:

1. **Berapa nilai rupiah barang yang ada di rak sekarang.**
2. **Berapa banyak barang yang hilang** tanpa tercatat sebagai penjualan (*shrinkage*): rusak, kedaluwarsa, salah hitung, atau hilang.

Keduanya adalah yang dijawab StokLens. Pembacaan tanggal kedaluwarsa per barang sempat masuk rencana, diuji, lalu dikeluarkan dari lingkup setelah pengukuran menunjukkan tidak dapat dikerjakan dari foto rak. Uraianya ada di §4.3.5.

Solusi yang ada di pasar tidak menjawab kondisi ini. Aplikasi stock opname berbasis barcode mensyaratkan setiap barang punya barcode yang terbaca dan di-scan satu per satu. Untuk warung dengan sachet renceng dan barang curah, syarat itu tidak terpenuhi. Sistem RFID mensyaratkan pemasangan tag per item, biaya yang tidak masuk akal untuk barang seharga Rp 500.

2.2 Posisi terhadap solusi sejenis

Sudah ada pemain yang menggarap arah serupa, antara lain WarungVision dan fitur "Smart AI Stock Opname" pada beberapa perangkat lunak kasir. **Kami tidak mengklaim sebagai yang pertama.** Yang membedakan StokLens ada lima, dan semuanya dapat ditunjukkan, bukan sekadar dinyatakan:

Pembeda	Penjelasan
Enrollment few-shot, nol retraining di lapangan	Barang baru didaftarkan dengan 3–5 foto. Tidak ada proses training yang harus dijalankan pemilik warung.
Menghitung <i>facing</i> di rak	Sistem menghitung barang yang benar-benar terlihat di rak, bukan membaca angka dari dokumen laporan lewat OCR.
Anti dobel-hitung berlapis	Pada mode video: tiga mekanisme independen (§4.3.4). Pada mode foto, yang menjadi mode utama, satu deteksi = satu barang sehingga masalahnya tidak muncul di dalam satu foto; risiko antar-foto ditekan lewat SOP dan rincian hitungan per foto yang dapat diperiksa pengguna.
Memperbaiki diri sendiri dari pemakaian	Barang yang gagal dikenali dapat diberi nama oleh pengguna, dan potongan gambarnya langsung memperkaya galeri pengenalan.
Berjalan lokal, tanpa API pihak ketiga	Seluruh inferensi berjalan di perangkat sendiri. Biaya per-scan nol, dan foto dagangan tidak pernah keluar dari toko. Pembeda paling tajam terhadap solusi yang bergantung pada layanan AI berbayar.

Poin terakhir bukan sekadar keunggulan teknis. Bagi pemilik warung, model bisnis berbasis biaya per-panggilan-API berarti biaya yang tumbuh seiring pemakaian, dan itu justru menghukum pengguna yang paling rajin melakukan opname.

3. Tujuan dan Manfaat

3.1 Tujuan

1. Pemilik warung dapat menyelesaikan opname satu rak **dalam hitungan menit** menggunakan kamera ponsel yang sudah dimilikinya, tanpa perangkat tambahan.
2. Hasilnya berupa **laporan selisih dalam rupiah**, bukan sekadar daftar angka deteksi, sehingga langsung dapat ditindaklanjuti.
3. Sistem **dapat dijalankan sepenuhnya offline** pada satu komputer di toko, diakses dari ponsel lewat jaringan setempat, tanpa langganan dan tanpa mengirim data ke pihak ketiga. Inferensi berjalan di komputer itu; ponsel berperan sebagai kamera dan antarmuka. Menjalankan model langsung di ponsel berada di luar lingkup penyisihan.

3.2 Manfaat

Bagi pemilik usaha: mengetahui nilai stok dan angka kehilangan yang selama ini tidak terukur, serta memiliki dasar angka untuk keputusan pembelian ulang.

Bagi ekosistem UMKM: menurunkan ambang masuk pencatatan stok yang selama ini hanya terjangkau ritel modern.

Aspek etika dan privasi: SOP pengambilan foto secara eksplisit melarang memotret orang, hanya rak barang. Seluruh data tersimpan lokal.

4. Metodologi

4.1 Arsitektur sistem


Aturan arsitektur yang dipegang sejak awal: **logika murni dipisah dari pembungkus model berat**. Seluruh pustaka berat (`torch` , `ultralytics` , `open_clip`) hanya diimpor di dalam fungsi atau di satu modul pembungkus, tidak pernah di tingkat modul yang memuat logika.

Konsekuensinya dapat diuji, bukan diklaim: **seluruh test cepat berjalan tanpa `torch` terpasang**, dan pipeline CI membuktikannya pada setiap pull request karena lingkungan CI memang sengaja tidak memasang tumpukan torch.



Keputusan: SQLite satu berkas, bukan basis data terpisah. Target pengguna adalah warung dengan ratusan SKU, bukan ribuan cabang. SQLite menghilangkan kebutuhan menjalankan layanan basis data, membuat seluruh aplikasi dapat dijalankan dengan satu perintah `docker compose up` , dan membuat cadangan data sesederhana menyalin satu berkas.


4.2 Alur inti: enroll → scan → laporan selisih



Panah putus-putus adalah kunci akurasi jangka panjang dan dirinci di §4.5.


4.3 Alur pengembangan tiap fitur

4.3.1 Enrollment: pengenalan tanpa retraining



Keputusan: CLIP zero-shot, bukan melatih pengklasifikasi. Melatih pengklasifikasi berarti setiap warung harus melatih ulang model setiap kali menambah barang, dan itu mustahil dijalankan pemilik warung. Dengan perbandingan embedding, menambah barang cukup menambah satu baris di basis data.


4.3.2 Mode FOTO: jalur utama untuk warung



Keputusan: mode foto jadi mode utama, bukan video. Dalam satu foto, satu deteksi = satu barang, sehingga seluruh kelas masalah "satu barang terhitung dua kali karena ID tracking pecah" tidak pernah muncul. Mode foto juga jauh lebih murah (enam foto sekitar 18 MB dibanding video sekitar 75 MB), dan foto diam tidak membawa blur gerakan seperti frame video, sehingga potongan yang masuk ke pencocokan lebih tajam. Untuk warung yang sempit, mundur beberapa langkah untuk merekam sweep sering kali tidak mungkin.

Risikonya berpindah ke antar-foto: zona tumpang tindih bisa terhitung dua kali. Mitigasinya SOP satu foto satu sub-segmen berbatas fisik, ditambah **rincian hitungan per foto** yang ditampilkan di antarmuka sehingga pengguna dapat melihat dan mengoreksi sendiri.


4.3.3 Mode VIDEO untuk rak panjang



Arah sweep tidak perlu dideklarasikan pengguna, ditentukan otomatis dari mayoritas arah penyeberangan seluruh track.

4.3.4 Anti dobel-hitung: tiga lapis independen

Ini masalah paling menentukan pada mode video, dan diselesaikan berlapis karena tidak ada satu mekanisme yang cukup:



Alasan tiap lapis, dan apa yang gagal ditangani lapis sebelumnya:

Lapis	Menangani	Yang masih lolos
Tracking	Satu barang di banyak frame	ID pecah → barang sama dapat dua ID
ReID + buffer	ID pecah karena blur/terhalang sesaat	ID pecah yang terlalu jauh jaraknya
Line-crossing	ID pecah di sisi layar yang sama, hanya satu yang sempat menyeberang	Track sangat pendek dari noise
Filter umur	Noise berumur pendek	tidak ada

Histeresis pada line-crossing menyerap goyangan kamera kecil di sekitar garis. Penyeberangan balik menghasilkan event bernilai -1 yang saling menghapus dengan $+1$ sebelumnya, sehingga hitungan **mengoreksi dirinya sendiri** ketika kamera sempat mundur.

4.3.5 Pembacaan tanggal kedaluwarsa: diuji, lalu dikeluarkan dari lingkup

Rencana awal menyertakan pembacaan tanggal kedaluwarsa langsung dari foto rak. Komponennya dibangun: parser tanggal untuk format kemasan Indonesia (EXP , ED , BB , BAIK SEBELUM , BEST BEFORE , dengan pola tanggal-bulan-tahun, nama-bulan-tahun seperti AGU 26 , maupun bulan-tahun; nama bulan Indonesia dan Inggris dipetakan bersamaan karena keduanya lazim pada kemasan yang sama). Parser itu selesai dan lulus 11 pengujian otomatis.

Yang tidak pernah divalidasi adalah pasangannya: apakah OCR sanggup menghasilkan teks tanggal itu dari potongan foto rak. Kami mengukurnya:

Kondisi	Potongan diuji	Menghasilkan teks	Tanggal kedaluwarsa terbaca
Resolusi penuh	64	43	0
Setelah pengecilan ke 1280 px	53	33	0

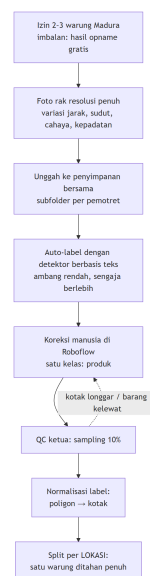
Nol dari 64. OCR-nya sendiri bekerja: 43 dari 64 potongan menghasilkan teks berupa nama merek dan tulisan besar kemasan. Yang tidak pernah muncul justru tanggalnya, dan resolusi penuh pun tetap nol.

Sebabnya struktural, bukan soal ketajaman gambar. Tanggal kedaluwarsa pada kemasan Indonesia dicetak inkjet atau laser tipis berkontras rendah, dan letaknya di belakang, di bawah, atau pada lipatan sambungan, sedangkan sisi yang menghadap rak justru sisi yang tidak membawa tanggal. Informasi itu tidak berada di dalam frame, sehingga menaikkan resolusi tidak akan menolong.

Keputusan: dikeluarkan dari lingkup MVP. Fitur ini tidak ditampilkan sebagai kemampuan produk dan tidak didemonstrasikan. Menyertakannya berarti menjanjikan sesuatu yang, berdasarkan pengukuran kami sendiri, tidak akan berjalan di tangan pemilik warung.

Jalan yang masuk akal bila diteruskan kelak adalah **foto close-up terpisah** untuk barang yang perlu diperiksa, bukan mengharapkan satu foto rak melayani dua tujuan yang menuntut jarak pengambilan berbeda. Kolom `expired_terdekat` dan `qty_expired` tetap ada pada skema (\$4.7) karena jalur akuntansinya sudah terpasang dan teruji; keduanya kini selalu kosong.

4.4 Alur perolehan dataset



Keputusan: split per lokasi, bukan split acak. Ini dua langkah terakhir di atas, dan keduanya lahir dari kegagalan yang diuraikan di §5.2. Split acak bawaan akan menaruh foto yang nyaris kembar 3–5 jepretan rak yang sama dalam hitungan detik di data latih *dan* data uji sekaligus. Angka yang keluar akan terlihat jauh lebih baik dan tidak berarti apa-apa.

Keputusan: satu kelas produk saja, bukan satu kelas per merek. Detektor hanya perlu menjawab "di mana ada barang"; pengenalan merek dikerjakan CLIP. Pemisahan ini membuat pekerjaan pelabelan jauh lebih cepat **dan** membuat penambahan barang baru tidak memerlukan pelabelan ulang apa pun.

Keputusan: menolak scraping marketplace. Selain melanggar ketentuan layanan dan hak cipta, jenis datanya salah: foto katalog berlatar putih, bukan adegan rak. Model yang dilatih dengan data seperti itu justru belajar bias yang tidak pernah ada di gudang.

Keputusan: foto diambil di warung Madura, bukan grosir. Model dasar sudah dilatih pada rak supermarket; jika data sendiri juga diambil di lingkungan rapi seperti grosir, satu jurang domain ditutup sementara jurang kedua dibuka. Ciri warung yang tidak ada pada dataset supermarket: **sachet renceng yang digantung**, cahaya bohlam hangat, rak improvisasi, dan ruang sempit.


Keputusan pelabelan renceng: satu sachet = satu kotak. Alasannya bukan teknis melainkan bisnis: warung menjual dan menghitung stoknya per sachet. Jika model menghitung per renceng, angka selisih pada laporan tidak akan cocok dengan cara pemilik warung menghitung, dan seluruh fitur kehilangan maknanya baginya.

4.5 Perbaiki akurasi lewat pemakaian

Analisis kegagalan pencocokan menunjukkan penyebab utamanya **bukan** kemiripan antar produk, melainkan **ketidakcocokan kondisi**: foto enrollment diambil dekat, terang, dan tegak lurus, sementara potongan hasil scan berukuran kecil, agak blur, dan menyerong. Urutan faktor perusak, dari yang paling parah:

1. Perbedaan skala dan ketajaman
2. Perbedaan cahaya dan suhu warna
3. Perbedaan sudut
4. Latar belakang rak
5. Foto stok dari internet, paling buruk, karena desain kemasannya sering sudah versi lama

Solusinya menghilangkan ketidakcocokan itu di akarnya:




Keputusan: galeri banyak-vektor, BUKAN merata-ratakan. Ini keputusan yang sempat diambil salah lalu dikoreksi. Rencana awal adalah merata-ratakan vektor enrollment dengan vektor potongan scan. Analisis menunjukkan hasilnya justru buruk: merata-ratakan foto tampak-depan yang rapi dengan potongan menyerong yang blur menghasilkan vektor yang **tidak mirip keduanya**. Yang akhirnya

dibangun adalah galeri berisi entri terpisah, dan pencocokan mengambil **similarity tertinggi** di antara seluruh entri milik produk tersebut.

Keputusan: vektor dihitung saat scan, bukan saat pengguna memberi nama. Konsekuensinya endpoint pemberian nama tidak perlu memuat CLIP sama sekali, responsnya cepat dan dapat diuji tanpa torch. Biayanya sekitar 2 KB per potongan.


4.6 Alur integrasi model ke lingkungan kode

Model diperlakukan sebagai **dependensi yang dapat ditukar**, bukan bagian dari kode. Bobot model tidak pernah masuk ke repositori, melainkan dibagikan lewat penyimpanan bersama tim, dan repositori memblokirnya lewat `.gitignore`.



Keputusan: pre-train dua tahap, bukan langsung fine-tune dari COCO. Dataset sendiri terlalu kecil untuk mengajarkan bentuk umum "rak penuh produk yang rapat". SKU-110K mengajarkan itu; dataset sendiri mengajarkan kondisi lokal.


Hasil Tahap 1 yang sudah dicapai (RTX 4070, 20 epoch, 37 menit):



Epoch	mAP50	mAP50-95
1	0,756	0,408
11	0,850	0,505
20 (final)	0,868	0,525

Validasi akhir pada 588 gambar berisi 90.968 objek: presisi 0,894, recall 0,816, waktu inferensi 1,7 ms per gambar. Kurva sudah melandai: dari epoch 11 ke 20 hanya naik 0,018 sehingga 20 epoch dinilai sebagai titik henti yang tepat, bukan angka yang dipilih sembarangan.


Hasil Tahap 2 (22 Agustus 2026). Fine-tune dijalankan pada dataset warung sendiri, 60 epoch, 30 menit di RTX 4070.



Cara pengujian, dan kenapa caranya begitu

Angka di bawah ini diukur pada **85 foto dari satu warung yang seluruhnya ditahan dari data latih**. Model tidak pernah melihat satu pun foto dari lokasi itu. Pilihan ini disengaja dan penting.

Split acak bawaan Roboflow akan memberi angka yang jauh lebih tinggi, tetapi tidak sah: SOP pemotretan kami mengambil 3–5 foto per rak dalam hitungan detik, sehingga foto yang nyaris kembar akan tersebar ke data latih *dan* data uji. Model akan dinilai pada rak yang sudah pernah dilihatnya. Angka yang keluar mengukur ingatan, bukan kemampuan menghadapi warung baru, dan warung baru persis yang dihadapi produk ini setiap kali dipasang di toko berikutnya.




Pengukuran	YOLO11n COCO (sebelum)	Fine-tune 1 tahap	Fine-tune 2 tahap
mAP50	0,304	0,787	0,827
mAP50-95	0,209	0,523	0,569
Precision	0,617	0,779	0,795
Recall	0,279	0,752	0,787

Yang paling berarti untuk produk adalah **recall**: 0,279 → 0,787. Model generik hanya menemukan 28% barang di rak; setelah fine-tune menjadi 79%. Barang yang tidak terdeteksi tidak akan pernah terhitung, sehingga recall-lah yang membatasi akurasi opname, bukan mAP.

Tahap 1 terbukti menyumbang, bukan sekadar cerita kepatuhan. Fine-tune yang berangkat dari checkpoint SKU-110K mengungguli fine-tune langsung dari COCO sebesar +0,040 mAP50 dan +0,034 recall, dengan dataset, jumlah epoch, dan seluruh hyperparameter yang identik. Selisih itu satu-satunya yang berbeda: titik awal bobot.

4.7 Skema data



Keputusan: stok disimpan sebagai buku besar (ledger), bukan satu kolom angka. Angka selisih tidak bermakna tanpa angka pembanding yang tercatat beserta asal-usulnya. Ledger membuat setiap perubahan stok dapat ditelusuri: berasal dari opname yang mana, atau penyesuaian manual dengan alasan apa.

Penerapan hasil opname ke ledger berjalan dalam **satu transaksi atomik** dengan penjagaan *compare-and-set*, sehingga dua permintaan bersamaan tidak dapat menerapkan opname yang sama dua kali.

5. Metode Pendukung Pengambilan Keputusan

Bagian ini merangkum bagaimana keputusan diambil, bukan sekadar apa yang diputuskan.

5.1 Keputusan yang diubah setelah analisis

Keputusan awal	Diubah menjadi	Dasar perubahan
Rata-ratakan vektor enrollment dengan vektor scan	Galeri banyak-vektor, ambil similarity tertinggi	Analisis: rata-rata dua kondisi yang sangat berbeda menghasilkan vektor yang tidak mirip keduanya
Hitung per track ID	Tambah line-crossing sebagai lapis ketiga	Uji: ID pecah membuat satu barang terhitung dua kali
Video sebagai mode utama	Foto sebagai mode utama	Analisis biaya dan kelas kesalahan: satu foto = satu deteksi per barang, tidak ada masalah ID pecah
Ambil foto dataset di toko grosir	Ambil di warung Madura	Analisis domain: model dasar sudah dilatih pada rak rapi; mengambil data di lingkungan rapi membuka jurang domain kedua
Bangun export dan analitik tambahan	Dibatalkan	Ruang lingkup MVP harus tetap pada alur inti

5.2 Kegagalan yang terdokumentasi


Dokumentasi tim menyimpan **alasan penolakan**, bukan hanya keputusan yang diterima. Dua contoh yang berdampak nyata:

Konflik semantik antar cabang. Dua cabang yang masing-masing lulus pengujian dapat menghasilkan kegagalan setelah digabung, karena konfliknya bersifat makna, bukan tekstual: git melaporkan penggabungan bersih, tetapi pengujian gabungan gagal. Terjadi dua kali sebelum akhirnya dijadikan aturan tertulis: **cabang yang menyentuh berkas sama wajib menggabungkan cabang utama dan menjalankan pengujian sebelum digabung**. Aturan turunannya: uji penjaga harus menguji **pola**, bukan keberadaan kata.

Regresi yang lahir dari perbaikan. Pada satu unit, perbaikan atas kondisi balapan justru menimbulkan cacat baru berupa tombol yang tidak pernah aktif kembali. Ditemukan pada putaran review ketiga. Ini menjadi alasan mengapa peninjauan dilakukan berlapis dan hasilnya ditulis ke dokumen rencana, bukan dibiarkan hilang di percakapan.

Kerusakan label yang tidak menimbulkan satu pun pesan galat. Roboflow menyediakan *Smart Polygon* untuk mengikuti lekuk barang, dan pelabel kami memakainya untuk bentuk sulit seperti kerupuk gantung dan renceng melengkung, sambil tetap memakai kotak biasa untuk dus. Wajar, dan dokumentasi internal kami sendiri sempat menyatakan pencampuran itu tidak bermasalah.

Ternyata bermasalah, di tempat yang tidak terlihat. Ekspor format YOLO menulis koordinat poligon apa adanya, lalu pustaka pelatihan memeriksa bentuk label **per berkas, bukan per baris**: satu baris poligon membuat seluruh baris di berkas itu dibaca sebagai poligon. Baris kotak `cls cx cy w h` ditafsirkan sebagai dua titik: titik pusat dan ukuran diperlakukan sebagai dua sudut, sehingga kotaknya tidak lagi berhubungan dengan barang aslinya.



Diukur pada gabungan ekspor kami: dari **11.779 anotasi**, 3.751 berbentuk poligon dan **2.339 kotak (19,9% dari seluruh anotasi) berada di 116 berkas campuran** dan akan rusak. Berkas yang isinya seragam, semua kotak atau semua poligon, justru aman; yang mematikan adalah pencampuran di dalam satu foto.

Temuan ini menghasilkan langkah normalisasi wajib sebelum pelatihan, dan koreksi pada panduan internal yang sebelumnya keliru. Kami mencantumkan di sini karena kegagalan jenis ini, yang tidak memunculkan galat, tidak menggagalkan pengujian, dan hanya menyisakan model yang lebih buruk tanpa sebab yang jelas, adalah kegagalan yang paling mahal dalam proyek pembelajaran mesin, dan satu-satunya pertahanannya adalah memeriksa data, bukan menunggu peringatan.

Fitur yang dibatalkan setelah diukur. Pembacaan tanggal kedaluwarsa direncanakan sejak awal, parsernya dibangun dan lulus 11 pengujian, dan komponennya sudah terpasang di alur. Yang tidak pernah diperiksa justru asumsi dasarnya: bahwa tanggal itu terlihat pada foto rak. Ketika akhirnya diukur, hasilnya **nol dari 64 potongan**, pada resolusi penuh sekalipun (\$4.3.5).


Fitur itu dikeluarkan dari lingkup, bukan dipertahankan sebagai janji. Kami mencatatnya karena urutan kejadiannya sendiri adalah pelajaran: pekerjaan mengalir ke komponen yang paling mudah dibangun dan diuji, yaitu parser teks, sementara asumsi yang menopang seluruh fitur dibiarkan tak tersentuh sampai akhir. Pengujian yang paling berguna bukan yang paling mudah ditulis, melainkan yang menyerang asumsi paling rapuh.

5.3 Parameter yang dapat disetel, dan cara menyetelnya

Parameter	Nilai berlaku	Gejala bila terlalu rendah	Gejala bila terlalu tinggi
Ambang pencocokan	0,85 (diukur)	Barang asing disangka produk terdaftar	Banyak item "belum dikenali"
Umur minimum track	3 frame	Noise ikut terhitung	Barang yang sekilas terlihat terlewat
Interval pengambilan embedding	tiap 5 frame	Lambat	Suara terlalu sedikit untuk memilih label

Ambang pencocokan: dari tebakan menjadi pengukuran

Nilai 0,75 yang dipakai di awal tidak pernah divalidasi: dasarnya hanya tiga kasus tunggal, dan itu anekdot. Kami mengukurnya ulang pada **12 produk dan 104 foto** dengan dua uji terpisah: *leave-one-out* untuk kemampuan mengenali, dan *leave-one-product-out* untuk kemampuan menolak.



Pengukuran itu memperlihatkan hal yang tidak terlihat sebelumnya: **pada 0,75, satu dari tiga barang yang belum didaftarkan disangka produk lain** 33 dari 104. Di laporan opname, kesalahan itu muncul sebagai barang dengan nama yang salah. Ini jenis kesalahan paling merusak, karena hasilnya terbaca meyakinkan dan tidak meninggalkan tanda apa pun bahwa ada yang keliru.

Ambang mana yang terbaik bergantung pada komposisi rak:

Rasio barang asing : terdaftar	Ambang terbaik
1 : 1	0,80
3 : 1 (rak warung nyata)	0,85

Warung mendaftarkan puluhan produk sementara raknya memuat ratusan barang, sehingga barang yang belum terdaftar jauh lebih banyak. **Keputusan: naik ke 0,85.** Konsekuensinya diterima secara sadar:

pengenalan produk terdaftar turun dari 0,933 ke 0,673, ditukar dengan kesalahan penamaan yang turun dari 33 kasus menjadi nol. Bagi pemilik warung, "belum dikenali" adalah barang yang tinggal diberi nama sekali; "salah nama" adalah angka rupiah yang salah tanpa ia sadari.

5.4 Cara memverifikasi klaim

Klaim modularitas diverifikasi mesin, bukan pernyataan: pipeline CI memasang lingkungan **tanpa** tumpukan torch dan menjalankan seluruh test cepat pada setiap pull request. Pipeline terpisah **membangun image kontainer dan menguji aplikasinya benar-benar melayani permintaan**, sehingga klaim "dapat dijalankan dengan satu perintah" tidak bergantung pada laptop siapa pun.

6. Kesiapan dan Cara Menjalankan

Seluruh aplikasi berjalan lokal dengan satu perintah:

```
docker compose up --build
```

● **Hasil uji lapangan**, diisi setelah pengujian di warung:

Pengukuran	Hasil
Jumlah barang yang didaftarkan	<...>
Akurasi hitungan dibanding hitung manual	<...>
Waktu opname satu rak	<...>
Tanggapan pemilik warung	<...>

7. Kesimpulan

StokLens menjawab persoalan yang nyata dan terukur: pemilik warung tidak mengetahui nilai stok dan angka kehilangannya karena menghitung manual terlalu mahal. Pendekatan yang dipilih (deteksi produk pada foto rak, pengenalan berbasis perbandingan embedding tanpa retraining, dan pelaporan selisih dalam rupiah) memungkinkan opname dilakukan dengan perangkat yang sudah dimiliki pemilik warung.

Tiga hal yang kami anggap paling menentukan:

1. **Berjalan lokal sepenuhnya.** Biaya per-scan nol dan data tidak pernah keluar dari toko, pembeda terhadap solusi yang bergantung pada layanan AI berbayar.
2. **Memperbaiki diri dari pemakaian.** Setiap barang yang gagal dikenali lalu diberi nama pengguna memperkaya galeri dalam kondisi yang identik dengan kondisi pemakaian nyata.
3. **Keputusan berbasis analisis, termasuk yang dikoreksi.** Beberapa keputusan penting justru merupakan pembatalan rencana awal setelah analisis menunjukkan rencana itu keliru: ambang

pencocokan yang dinaikkan setelah diukur, dan panduan pelabelan internal yang dikoreksi setelah ditemukan merusak 20% anotasi tanpa memunculkan galat.

Fine-tune dua tahap sudah selesai dan terukur pada warung yang seluruhnya ditahan dari data latih: **mAP50 0,304 → 0,827** dan **recall 0,279 → 0,787**. Recall adalah angka yang membatasi akurasi opname, karena barang yang tidak terdeteksi tidak akan pernah terhitung.

● Angka uji lapangan di warung melengkapi proposal ini sebelum pengumpulan.

Lampiran A: Ringkasan Keputusan Teknis

#	Keputusan	Alasan singkat
1	SQLite satu berkas	Skala warung; satu perintah jalan; cadangan = salin berkas
2	CLIP zero-shot, bukan pengklasifikasi terlatih	Barang baru tidak boleh memerlukan retraining
3	Satu kelas produk pada detektor	Pelabelan cepat; barang baru tidak perlu pelabelan ulang
4	Mode foto sebagai mode utama	Satu deteksi = satu barang; lebih murah; tanpa blur gerakan
5	Anti dobel-hitung berlapis tiga	Tidak ada satu mekanisme yang cukup
6	Galeri banyak-vektor, bukan rata-rata	Rata-rata dua kondisi berbeda tidak mirip keduanya
7	Vektor dihitung saat scan	Endpoint pemberian nama bebas CLIP, cepat, dapat diuji
8	Ledger, bukan kolom angka	Selisih tidak bermakna tanpa pembandingan yang tertelusur
9	Pre-train dua tahap	Dataset sendiri terlalu kecil untuk bentuk umum rak
10	Foto dataset dari warung, bukan grosir	Menghindari jurang domain kedua
11	Satu sachet = satu kotak pada renceng	Menyamakan dengan cara warung menghitung stok
12	Menolak scraping marketplace	Melanggar ketentuan layanan dan jenis datanya salah