

Daftar Tautan

Nama tim: The Goyzalis 2.0

Judul proyek: StokLens, Stock Opname Otomatis Berbasis Visi Komputer untuk Warung dan Toko Kelontong

Tema: Smart Logistics

Keperluan	Tautan
Repositori GitHub	https://github.com/marshal-rizky/Stocklens
Video Proof of Work	https://www.youtube.com/watch?v=igz4EEkHIPI
Video Promosi Inovasi	https://www.youtube.com/watch?v=LYg2WpKdffU

Bobot detektor hasil pelatihan tidak disimpan di dalam repositori, dan tanpa bobot itu aplikasi berjalan memakai model COCO bawaan yang memberi nol kotak pada foto rak. Berkasnya (5,4 MB) dilampirkan pada rilis:

<https://github.com/marshal-rizky/Stocklens/releases/tag/bobot-v1>

Cara mengarahkannya ada di README bagian "Menukar bobot detektor". Aplikasi tidak memerlukan berkas `.env` maupun kredensial apa pun untuk pengujian lokal.

StokLens

1. Nama Tim dan Judul Proyek

Nama tim: The Goyzalis 2.0

Judul: StokLens, Stock Opname Otomatis Berbasis Visi Komputer untuk Warung dan Toko Kelontong

Anggota: Marshal Rizky Raditya · Danish Ahmad Satria · Nicolas Nathan Abimanyu · Muhammad Bhre Zidane Pribadi · Muhammad Noby Ghazali

Tema: Smart Logistics

2. Latar Belakang

2.1 Masalah

Toko kelontong tradisional adalah bentuk ritel paling banyak di Indonesia: **3,94 juta unit, setara 98,78% dari seluruh ritel** [1]. Jumlah itu sedang menyusut. Menurut APKLI, yang tersisa hingga akhir 2025 sekitar **3,9 juta unit, turun dari 6,1 juta pada 2007** [2]. Lebih dari dua juta warung tutup dalam delapan belas tahun, sebagian besar kalah bersaing dengan ritel modern.

Salah satu yang membedakan ritel modern bukan modalnya, melainkan bahwa mereka **tahu angka stoknya**. Ritel modern mengukur kehilangan yang tidak tercatat sebagai penjualan, dan di Amerika Serikat angkanya rata-rata **1,6% dari penjualan**, atau 112,1 miliar dolar setahun [3]. Angka itu diketahui justru karena mereka menghitung. Warung tidak punya angka bandingannya sama sekali, bukan karena kehilangannya lebih kecil, melainkan karena tidak ada yang menghitungnya.

Alasannya bukan kemalasan, melainkan biaya: menghitung ratusan SKU secara manual memakan waktu berjam-jam dan harus dilakukan saat toko tutup. Sejalan dengan itu, **77% UMKM Indonesia masih mencatat keuangan secara manual** [4]. Akibatnya pemilik tidak pernah tahu dua angka yang menentukan kelangsungan usahanya:

1. **Berapa nilai rupiah barang yang ada di rak sekarang.**
2. **Berapa banyak barang yang hilang** tanpa tercatat sebagai penjualan (*shrinkage*): rusak, kedaluwarsa, salah hitung, atau hilang.

Keduanya adalah yang dijawab StokLens. Pembacaan tanggal kedaluwarsa per barang sempat masuk rencana, diuji, lalu dikeluarkan dari lingkup setelah pengukuran menunjukkan tidak dapat dikerjakan dari foto rak. Uraianya ada di §4.3.5.

Solusi yang ada di pasar tidak menjawab kondisi ini. Aplikasi stock opname berbasis barcode mensyaratkan setiap barang punya barcode yang terbaca dan di-scan satu per satu. Untuk warung

dengan sachet renceng dan barang curah, syarat itu tidak terpenuhi. Sistem RFID mensyaratkan pemasangan tag per item, biaya yang tidak masuk akal untuk barang seharga Rp 500.

2.2 Posisi terhadap solusi sejenis

Sudah ada pemain yang menggarap arah serupa, antara lain WarungVision dan fitur "Smart AI Stock Opname" pada beberapa perangkat lunak kasir. **Kami tidak mengklaim sebagai yang pertama.** Yang membedakan StokLens ada lima, dan semuanya dapat ditunjukkan, bukan sekadar dinyatakan:

Pembeda	Penjelasan
Enrollment few-shot, nol retraining di lapangan	Barang baru didaftarkan dengan 3–5 foto. Tidak ada proses training yang harus dijalankan pemilik warung.
Menghitung facing di rak	Sistem menghitung barang yang benar-benar terlihat di rak, bukan membaca angka dari dokumen laporan lewat OCR.
Anti dobel-hitung berlapis	Pada mode video: tiga mekanisme independen (§4.3.4). Pada mode foto, yang menjadi mode utama, satu deteksi = satu barang sehingga masalahnya tidak muncul di dalam satu foto; risiko antar-foto ditekan lewat SOP dan rincian hitungan per foto yang dapat diperiksa pengguna.
Memperbaiki diri sendiri dari pemakaian	Barang yang gagal dikenali dapat diberi nama oleh pengguna, dan potongan gambarnya langsung memperkaya galeri pengenalan.
Berjalan lokal, tanpa API pihak ketiga	Seluruh inferensi berjalan di perangkat sendiri. Biaya per-scan nol, dan foto dagangan tidak pernah keluar dari toko. Pembeda paling tajam terhadap solusi yang bergantung pada layanan AI berbayar.

Poin terakhir bukan sekadar keunggulan teknis. Bagi pemilik warung, model bisnis berbasis biaya per-panggilan-API berarti biaya yang tumbuh seiring pemakaian, dan itu justru menghukum pengguna yang paling rajin melakukan opname.

3. Tujuan dan Manfaat

3.1 Tujuan

1. Pemilik warung dapat menyelesaikan opname satu rak **dalam hitungan menit** menggunakan kamera ponsel yang sudah dimilikinya, tanpa perangkat tambahan.
2. Hasilnya berupa **laporan selisih dalam rupiah**, bukan sekadar daftar angka deteksi, sehingga langsung dapat ditindaklanjuti.
3. Sistem **dapat dijalankan sepenuhnya offline** pada satu komputer di toko, diakses dari ponsel lewat jaringan setempat, tanpa langganan dan tanpa mengirim data ke pihak ketiga. Inferensi berjalan di komputer itu; ponsel berperan sebagai kamera dan antarmuka. Menjalankan model langsung di ponsel berada di luar lingkup penyisihan.

3.2 Manfaat

Bagi pemilik usaha: mengetahui nilai stok dan angka kehilangan yang selama ini tidak terukur, serta memiliki dasar angka untuk keputusan pembelian ulang.

Bagi ekosistem UMKM: menurunkan ambang masuk pencatatan stok yang selama ini hanya terjangkau ritel modern.

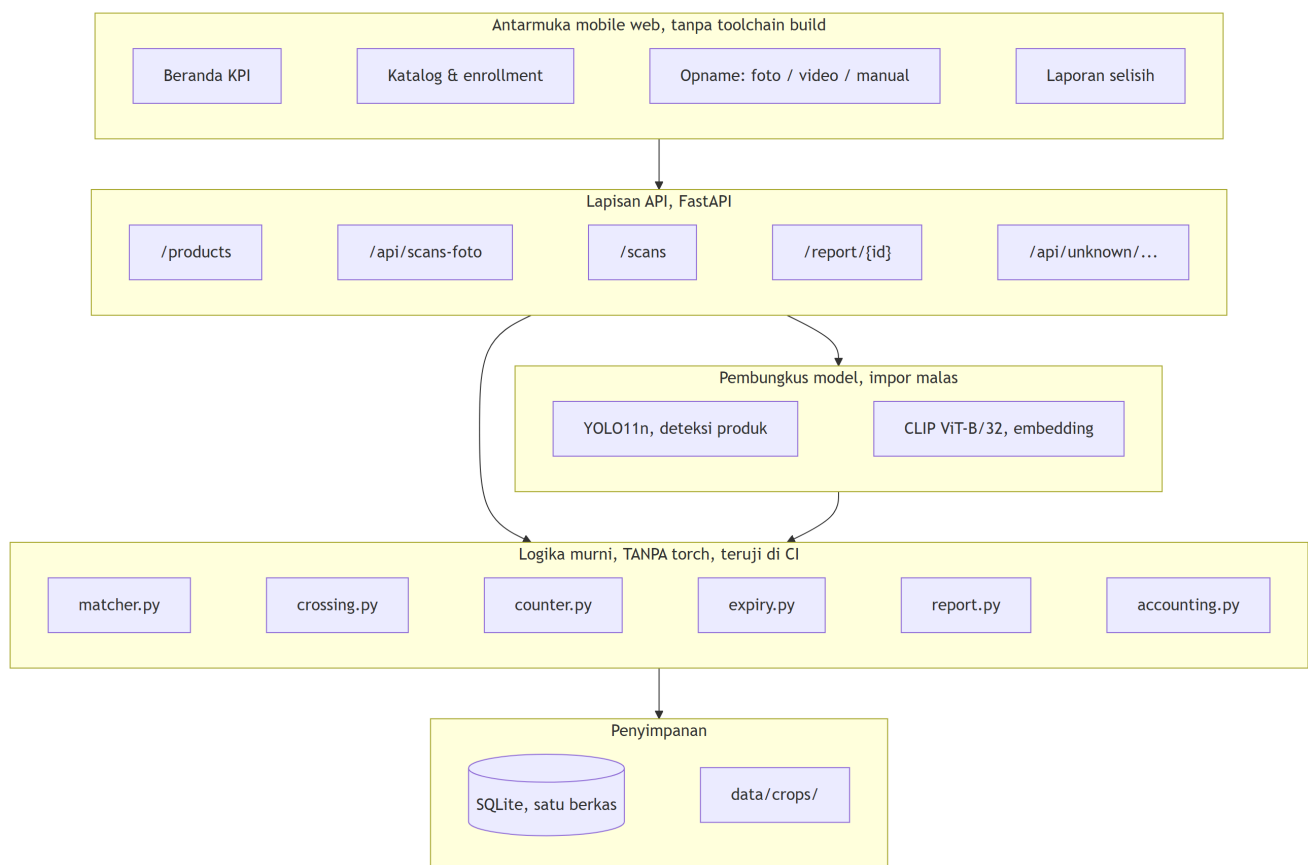
Aspek etika dan privasi: SOP pengambilan foto secara eksplisit melarang memotret orang, hanya rak barang. Seluruh data tersimpan lokal.

4. Metodologi

4.1 Arsitektur sistem


Aturan arsitektur yang dipegang sejak awal: **logika murni dipisah dari pembungkus model berat**. Seluruh pustaka berat (`torch` , `ultralytics` , `open_clip`) hanya diimpor di dalam fungsi atau di satu modul pembungkus, tidak pernah di tingkat modul yang memuat logika.

Konsekuensinya dapat diuji, bukan diklaim: **seluruh test cepat berjalan tanpa `torch` terpasang**, dan pipeline CI membuktikannya pada setiap pull request karena lingkungan CI memang sengaja tidak memasang tumpukan torch.



Keputusan: SQLite satu berkas, bukan basis data terpisah. Target pengguna adalah warung dengan ratusan SKU, bukan ribuan cabang. SQLite menghilangkan kebutuhan menjalankan layanan basis data, membuat seluruh aplikasi dapat dijalankan dengan satu perintah `docker compose up`, dan membuat cadangan data sesederhana menyalin satu berkas.


4.2 Alur inti: enroll → scan → laporan selisih



Panah putus-putus adalah kunci akurasi jangka panjang dan dirinci di §4.5.

4.3 Alur pengembangan tiap fitur


4.3.1 Enrollment: pengenalan tanpa retraining



Keputusan: CLIP zero-shot, bukan melatih pengklasifikasi. Melatih pengklasifikasi berarti setiap warung harus melatih ulang model setiap kali menambah barang, dan itu mustahil dijalankan pemilik

warung. Dengan perbandingan embedding, menambah barang cukup menambah satu baris di basis data.

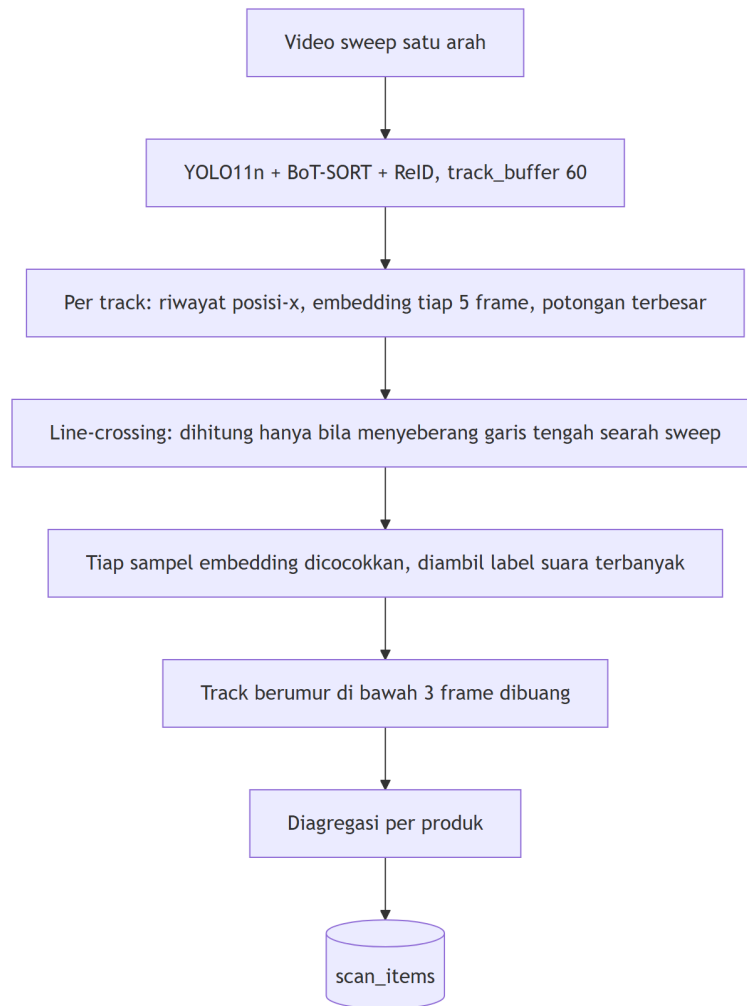
4.3.2 Mode FOTO: jalur utama untuk warung



Keputusan: mode foto jadi mode utama, bukan video. Dalam satu foto, satu deteksi = satu barang, sehingga seluruh kelas masalah "satu barang terhitung dua kali karena ID tracking pecah" tidak pernah muncul. Mode foto juga jauh lebih murah (enam foto sekitar 18 MB dibanding video sekitar 75 MB), dan foto diam tidak membawa blur gerakan seperti frame video, sehingga potongan yang masuk ke pencocokan lebih tajam. Untuk warung yang sempit, mundur beberapa langkah untuk merekam sweep sering kali tidak mungkin.

Risikonya berpindah ke antar-foto: zona tumpang tindih bisa terhitung dua kali. Mitigasinya SOP satu foto satu sub-segmen berbatas fisik, ditambah **rincian hitungan per foto** yang ditampilkan di antarmuka sehingga pengguna dapat melihat dan mengoreksi sendiri.


4.3.3 Mode VIDEO untuk rak panjang



Arah sweep tidak perlu dideklarasikan pengguna, ditentukan otomatis dari mayoritas arah penyeberangan seluruh track.

4.3.4 Anti dobel-hitung: tiga lapis independen

Ini masalah paling menentukan pada mode video, dan diselesaikan berlapis karena tidak ada satu mekanisme yang cukup:



Alasan tiap lapis, dan apa yang gagal ditangani lapis sebelumnya:

Lapis	Menangani	Yang masih lolos
Tracking	Satu barang di banyak frame	ID pecah → barang sama dapat dua ID
ReID + buffer	ID pecah karena blur/terhalang sesaat	ID pecah yang terlalu jauh jaraknya
Line-crossing	ID pecah di sisi layar yang sama, hanya satu yang sempat menyeberang	Track sangat pendek dari noise
Filter umur	Noise berumur pendek	tidak ada

Histeresis pada line-crossing menyerap goyangan kamera kecil di sekitar garis. Penyeberangan balik menghasilkan event bernilai -1 yang saling menghapus dengan $+1$ sebelumnya, sehingga hitungan **mengoreksi dirinya sendiri** ketika kamera sempat mundur.

4.3.5 Pembacaan tanggal kedaluwarsa: diuji, lalu dikeluarkan dari lingkup

Parser tanggal untuk format kemasan Indonesia (EXP , ED , BAIK SEBELUM , nama bulan Indonesia dan Inggris) selesai dan lulus 11 pengujian. **Yang tidak pernah divalidasi adalah pasangannya:** apakah OCR sanggup menghasilkan teks tanggal itu dari potongan foto rak. Kami mengukurnya:


Kondisi	Potongan diuji	Menghasilkan teks	Tanggal kedaluwarsa terbaca
Resolusi penuh	64	43	0
Setelah pengecilan ke 1280 px	53	33	0

OCR-nya sendiri bekerja: 43 dari 64 potongan menghasilkan teks berupa nama merek dan tulisan besar kemasan. Yang tidak pernah muncul justru tanggalnya.

Sebabnya struktural, bukan ketajaman gambar. Tanggal kedaluwarsa dicetak inkjet atau laser tipis berkontras rendah di belakang, di bawah, atau pada lipatan sambungan, sedangkan sisi yang menghadap rak justru sisi yang tidak membawanya. Informasi itu tidak ada di dalam frame, sehingga menaikkan resolusi tidak menolong.

Keputusan: dikeluarkan dari lingkup MVP dan tidak didemonstrasikan. Menyertakannya berarti menjanjikan sesuatu yang, menurut pengukuran kami sendiri, tidak akan berjalan di tangan pemilik warung. Jalan yang masuk akal bila diteruskan kelak adalah foto close-up terpisah, bukan mengharapkan satu foto rak melayani dua jarak pengambilan sekaligus.

4.4 Alur perolehan dataset



Split per lokasi, bukan split acak. Split acak bawaan menaruh foto yang nyaris kembar, 3–5 jepretan rak yang sama dalam hitungan detik, di data latih *dan* data uji sekaligus. Angkanya terlihat jauh lebih baik dan

tidak berarti apa-apa.

Satu kelas produk saja, bukan satu kelas per merek. Detektor hanya perlu menjawab "di mana ada barang"; pengenalan merek dikerjakan CLIP. Pelabelan jadi jauh lebih cepat, dan barang baru tidak memerlukan pelabelan ulang apa pun.

Menolak scraping marketplace. Selain melanggar ketentuan layanan dan hak cipta, jenis datanya salah: foto katalog berlatar putih, bukan adegan rak.

Foto diambil di warung Madura, bukan grosir. Model dasar sudah dilatih pada rak supermarket; mengambil data di grosir yang sama rapinya menutup satu jurang domain sambil membuka jurang kedua. Ciri warung yang tidak ada di dataset supermarket: sachet renceng yang digantung, cahaya bohlam hangat, rak improvisasi, ruang sempit.


Satu sachet = satu kotak, bukan satu renceng. Alasannya bisnis, bukan teknis: warung menjual dan menghitung per sachet. Kalau model menghitung per renceng, angka selisihnya tidak cocok dengan cara pemilik warung menghitung, dan laporannya kehilangan makna baginya.

4.5 Perbaiki akurasi lewat pemakaian

Analisis kegagalan pencocokan menunjukkan penyebab utamanya **bukan** kemiripan antar produk, melainkan **ketidakcocokan kondisi**: foto enrollment diambil dekat, terang, dan tegak lurus, sementara potongan hasil scan berukuran kecil, agak blur, dan menyerong. Urutan faktor perusak, dari yang paling parah:

1. Perbedaan skala dan ketajaman
2. Perbedaan cahaya dan suhu warna
3. Perbedaan sudut
4. Latar belakang rak
5. Foto stok dari internet, paling buruk, karena desain kemasannya sering sudah versi lama

Solusinya menghilangkan ketidakcocokan itu di akarnya:




Keputusan: galeri banyak-vektor, BUKAN merata-ratakan. Ini keputusan yang sempat diambil salah lalu dikoreksi. Rencana awal adalah merata-ratakan vektor enrollment dengan vektor potongan scan. Analisis menunjukkan hasilnya justru buruk: merata-ratakan foto tampak-depan yang rapi dengan potongan menyerong yang blur menghasilkan vektor yang **tidak mirip keduanya**. Yang akhirnya dibangun adalah galeri berisi entri terpisah, dan pencocokan mengambil **similarity tertinggi** di antara seluruh entri milik produk tersebut.

Keputusan: vektor dihitung saat scan, bukan saat pengguna memberi nama. Konsekuensinya endpoint pemberian nama tidak perlu memuat CLIP sama sekali, responsnya cepat dan dapat diuji tanpa torch. Biayanya sekitar 2 KB per potongan.


4.6 Alur integrasi model ke lingkungan kode

Model diperlakukan sebagai **dependensi yang dapat ditukar**, bukan bagian dari kode. Bobot model tidak pernah masuk ke repositori, melainkan dibagikan lewat penyimpanan bersama tim, dan repositori memblokirnya lewat `.gitignore`.



Keputusan: pre-train dua tahap, bukan langsung fine-tune dari COCO. Dataset sendiri terlalu kecil untuk mengajarkan bentuk umum "rak penuh produk yang rapat". SKU-110K mengajarkan itu; dataset sendiri mengajarkan kondisi lokal.


Hasil Tahap 1 yang sudah dicapai (RTX 4070, 20 epoch, 37 menit):



Epoch	mAP50	mAP50-95
1	0,756	0,408
11	0,850	0,505
20 (final)	0,868	0,525

Validasi akhir pada 588 gambar berisi 90.968 objek: presisi 0,894, recall 0,816, waktu inferensi 1,7 ms per gambar. Kurva sudah melandai: dari epoch 11 ke 20 hanya naik 0,018 sehingga 20 epoch dinilai sebagai titik henti yang tepat, bukan angka yang dipilih sembarangan.


Hasil Tahap 2 (22 Agustus 2026). Fine-tune dijalankan pada dataset warung sendiri, 60 epoch, 30 menit di RTX 4070.



Cara pengujian, dan kenapa caranya begitu

Angka di bawah ini diukur pada **85 foto dari satu warung yang seluruhnya ditahan dari data latih**. Model tidak pernah melihat satu pun foto dari lokasi itu. Pilihan ini disengaja dan penting.

Split acak bawaan Roboflow akan memberi angka yang jauh lebih tinggi, tetapi tidak sah: SOP pemotretan kami mengambil 3–5 foto per rak dalam hitungan detik, sehingga foto yang nyaris kembar akan tersebar ke data latih *dan* data uji. Model akan dinilai pada rak yang sudah pernah dilihatnya. Angka yang keluar mengukur ingatan, bukan kemampuan menghadapi warung baru, dan warung baru persis yang dihadapi produk ini setiap kali dipasang di toko berikutnya.




Pengukuran	YOLO11n COCO (sebelum)	Fine-tune 1 tahap	Fine-tune 2 tahap
mAP50	0,304	0,787	0,827
mAP50-95	0,209	0,523	0,569
Precision	0,617	0,779	0,795
Recall	0,279	0,752	0,787

Yang paling berarti untuk produk adalah **recall**: 0,279 → 0,787. Model generik hanya menemukan 28% barang di rak; setelah fine-tune menjadi 79%. Barang yang tidak terdeteksi tidak akan pernah terhitung, sehingga recall-lah yang membatasi akurasi opname, bukan mAP.

Tahap 1 terbukti menyumbang, bukan sekadar cerita kepatuhan. Fine-tune yang berangkat dari checkpoint SKU-110K mengungguli fine-tune langsung dari COCO sebesar +0,040 mAP50 dan +0,034 recall, dengan dataset, jumlah epoch, dan seluruh hyperparameter yang identik. Selisih itu satu-satunya yang berbeda: titik awal bobot.

4.7 Skema data



Keputusan: stok disimpan sebagai buku besar (ledger), bukan satu kolom angka. Angka selisih tidak bermakna tanpa angka pembanding yang tercatat beserta asal-usulnya. Ledger membuat setiap perubahan stok dapat ditelusuri: berasal dari opname yang mana, atau penyesuaian manual dengan alasan apa.

Penerapan hasil opname ke ledger berjalan dalam **satu transaksi atomik** dengan penjagaan *compare-and-set*, sehingga dua permintaan bersamaan tidak dapat menerapkan opname yang sama dua kali.

5. Metode Pendukung Pengambilan Keputusan

Bagian ini merangkum bagaimana keputusan diambil, bukan sekadar apa yang diputuskan.

5.1 Keputusan yang diubah setelah analisis


Keputusan awal	Diubah menjadi	Dasar perubahan
Rata-ratakan vektor enrollment dengan vektor scan	Galeri banyak-vektor, ambil similarity tertinggi	Analisis: rata-rata dua kondisi yang sangat berbeda menghasilkan vektor yang tidak mirip keduanya
Hitung per track ID	Tambah line-crossing sebagai lapis ketiga	Uji: ID pecah membuat satu barang terhitung dua kali
Video sebagai mode utama	Foto sebagai mode utama	Analisis biaya dan kelas kesalahan: satu foto = satu deteksi per barang, tidak ada masalah ID pecah
Ambil foto dataset di toko grosir	Ambil di warung Madura	Analisis domain: model dasar sudah dilatih pada rak rapi; mengambil data di lingkungan rapi membuka jurang domain kedua
Bangun export dan analitik tambahan	Dibatalkan	Ruang lingkup MVP harus tetap pada alur inti

5.2 Kegagalan yang terdokumentasi

Dokumentasi tim menyimpan **alasan penolakan**, bukan hanya keputusan yang diterima. Tiga yang berdampak nyata:

Konflik semantik antar cabang. Dua cabang yang masing-masing lulus pengujian bisa gagal setelah digabung, karena konfliknya bersifat makna: git melaporkan penggabungan bersih, pengujian gabungan tetap gagal. Terjadi dua kali, lalu jadi aturan tertulis: cabang yang menyentuh berkas sama wajib menggabungkan cabang utama dan menjalankan pengujian sebelum digabung.

Kerusakan label yang tidak menimbulkan satu pun pesan galat. Pelabel kami memakai *Smart Polygon* untuk barang berlekuk sambil tetap memakai kotak biasa untuk dus, dan dokumentasi internal kami sendiri menyatakan pencampuran itu tidak bermasalah. Ternyata bermasalah, di tempat yang tidak terlihat:



Terukur: dari **11.779 anotasi, 2.339 kotak (19,9%) berada di 116 berkas campuran** dan akan rusak. Berkas yang seragam justru aman; yang mematikan adalah pencampuran di dalam satu foto. Temuan ini menghasilkan langkah normalisasi wajib sebelum pelatihan dan koreksi pada panduan internal.

Fitur yang dibatalkan setelah diukur. Parser tanggal kedaluwarsa dibangun dan lulus 11 pengujian. Yang tidak pernah diperiksa justru asumsi dasarnya: bahwa tanggal itu terlihat pada foto rak. Ketika diukur, hasilnya **nol dari 64 potongan** (§4.3.5), dan fitur itu dikeluarkan dari lingkup.


Pola ketiganya sama, dan itulah alasan bagian ini ada: pekerjaan mengalir ke bagian yang paling mudah dibangun dan diuji, sementara asumsi yang menopangnya dibiarkan tak tersentuh. Kegagalan yang tidak memunculkan galat adalah yang paling mahal, dan pertahanannya cuma satu, memeriksa sendiri, bukan menunggu peringatan.

5.3 Parameter yang dapat disetel, dan cara menyetelnya

Parameter	Nilai berlaku	Gejala bila terlalu rendah	Gejala bila terlalu tinggi
Ambang pencocokan	0,80 (diukur dua kali)	Barang asing disangka produk terdaftar	Banyak item "belum dikenali"
Umur minimum track	3 frame	Noise ikut terhitung	Barang yang sekilas terlihat terlewat
Interval pengambilan embedding	tiap 5 frame	Lambat	Suara terlalu sedikit untuk memilih label

Ambang pencocokan: dari tebakan menjadi pengukuran

Nilai 0,75 yang dipakai di awal tidak pernah divalidasi: dasarnya hanya tiga kasus tunggal, dan itu anekdot. Kami mengukurnya ulang pada **12 produk dan 104 foto** dengan dua uji terpisah: *leave-one-out* untuk kemampuan mengenali, dan *leave-one-product-out* untuk kemampuan menolak.



Pengukuran itu memperlihatkan hal yang tidak terlihat sebelumnya: **pada 0,75, satu dari tiga barang yang belum didaftarkan disangka produk lain** 33 dari 104. Di laporan opname, kesalahan itu muncul sebagai barang dengan nama yang salah. Ini jenis kesalahan paling merusak, karena hasilnya terbaca meyakinkan dan tidak meninggalkan tanda apa pun bahwa ada yang keliru.

Ambang mana yang terbaik bergantung pada komposisi rak:

Rasio barang asing : terdaftar	Ambang terbaik
1 : 1	0,80
3 : 1 (rak warung nyata)	0,85

Warung mendaftarkan puluhan produk sementara raknya memuat ratusan barang, sehingga barang yang belum terdaftar jauh lebih banyak. Keputusan waktu itu: naik ke 0,85, dengan konsekuensi yang diterima

secara sadar. Pengenalan produk terdaftar turun dari 0,933 ke 0,673, ditukar dengan kesalahan penamaan yang turun dari 33 kasus menjadi nol. Bagi pemilik warung, "belum dikenali" adalah barang yang tinggal diberi nama sekali; "salah nama" adalah angka rupiah yang salah tanpa ia sadari.

Pengukuran kedua membatalkan angka itu

Seluruh tabel di atas dihitung dari **foto pendaftaran**: produk memenuhi bingkai, pencahayaan rata, tidak ada halangan. Catatan pengukuran pertama sudah menandai keterbatasan itu sebagai batas atas yang masih perlu diuji ulang memakai potongan yang benar-benar keluar dari detektor. Pengujian itu dijalankan pada satu foto rak lemari pendingin berisi 19 botol, tiga di antaranya sudah didaftarkan lewat alur pendaftaran normal:

Potongan	Skor tertinggi	Putusan pada 0,85	Kenyataan
Mizone	0,888	dikenali	benar
Teh pucuk	0,833	ditolak	salah tolak
Mizone kedua	0,741	ditolak	salah tolak
16 botol asing	0,613 tertinggi	ditolak	benar

Potongan yang keluar dari foto rak lebarnya hanya 63 sampai 110 piksel, miring, dan memantulkan cahaya kaca lemari pendingin. Skornya turun 0,05 sampai 0,11 dibanding foto pendaftaran, cukup untuk melewati batas 0,85 dari sisi yang salah.

Yang menentukan bukan dua salah tolak itu sendiri, melainkan **jarak antara 0,613 dan 0,741**. Pemisahan antara produk terdaftar dan barang asing masih lebar dan sehat, jadi yang keliru adalah letak ambangnya, bukan kemampuan model membedakan. **Keputusan: turun ke 0,80**, yang pada foto uji ini mengenali dua dari tiga produk terdaftar tanpa satu pun salah label.

Batasnya ditulis apa adanya: satu foto dengan tiga produk terdaftar tidak cukup untuk mengklaim angka recall, dan 16 barang asing tidak cukup untuk menaksir laju salah label pada 0,80. Yang dibuktikan hanya satu hal, yaitu bahwa 0,85 menolak produk terdaftar yang benar ketika potongannya berasal dari rak.

Pelajarannya bukan soal angka. Ambang pertama diukur dengan sungguh-sungguh, tetapi diukur pada distribusi yang salah, dan pengukuran yang teliti di atas data yang keliru tetap menghasilkan keputusan yang keliru. Karena itu ambang diperlakukan sebagai nilai yang harus diukur ulang setiap kali kondisi pengambilan gambar berubah, bukan sebagai konstanta yang sudah selesai. Uji lapangan berikutnya mengukurnya kembali pada rak dengan ratusan barang; bila di sana ada barang asing yang menembus 0,70, ambang tetap ini akan diganti ambang adaptif per produk.

5.4 Cara memverifikasi klaim

Klaim modularitas diverifikasi mesin, bukan pernyataan: pipeline CI memasang lingkungan **tanpa** tumpukan torch dan menjalankan seluruh test cepat pada setiap pull request. Pipeline terpisah **membangun image kontainer dan menguji aplikasinya benar-benar melayani permintaan**, sehingga klaim "dapat dijalankan dengan satu perintah" tidak bergantung pada laptop siapa pun.

6. Kesiapan dan Cara Menjalankan

Seluruh aplikasi berjalan lokal dengan satu perintah:

```
docker compose up --build
```

6.1 Uji lapangan pertama di warung

Diuji 22 Agustus 2026 pukul 18.28 sampai 18.40 WIB, dijalankan dari ponsel dengan aplikasi tetap berjalan di PC. Terowongan HTTP dipakai hanya untuk meneruskan permintaan dari ponsel ke PC itu; deteksi, pencocokan, dan basis datanya tetap sepenuhnya di mesin sendiri, sehingga klaim pemrosesan lokal di §2.2 tidak berubah oleh cara pengujian ini. Ambang pencocokan yang berlaku saat itu 0,80.

Pengukuran	Hasil
Produk didaftarkan di tempat	4
Foto rak di-scan	5
Objek terdeteksi	90
Dikenali otomatis saat scan	1, kemiripan 0,841
Dikenali setelah pengguna memberi nama	1
Sisanya masuk antrean "belum dikenali"	88
Jarak antar foto berurutan	26 sampai 43 detik
Menerapkan hasil ke buku stok	15 detik
Akurasi terhadap hitungan manual	tidak terukur, lihat di bawah

Satu pengenalan otomatis dari 90 deteksi adalah angka yang buruk bila dibaca sendirian, dan menyesatkan bila dibaca tanpa sebaran di bawah ini.

Dari 88 deteksi yang tertolak, potongannya tersimpan untuk 84; selisih 4 itu batas yang memang dipasang, yaitu maksimal 30 potongan per opname agar antrean tidak membanjiri disk. Dua di antaranya diberi nama pengguna di lokasi, menyisakan 82 yang kemiripannya dihitung ulang terhadap keempat galeri. Angka di bawah mencerminkan galeri sesudah dua penamaan itu, bukan saat scan berlangsung:

Kemiripan tertinggi	Jumlah potongan	Arti
di bawah 0,60	54	barang yang memang tidak pernah didaftarkan
0,60 sampai 0,70	23	barang lain, sebagian satu kategori
0,70 sampai 0,75	3	nyaris, tertolak ambang
0,80 ke atas	2	lihat paragraf berikut

Enam puluh enam persen penolakan terjadi pada barang berskor di bawah 0,60, yaitu barang yang memang bukan produk terdaftar. Uji ini mendaftarkan 4 produk lalu memotret rak berisi puluhan jenis

barang, sehingga sebagian besar penolakan adalah perilaku yang benar. Yang benar-benar hilang karena ambang hanya 3 potongan di rentang 0,70 sampai 0,75.

Dua potongan bernilai 0,898 dan 0,872 tetap di antrean bukan karena ambang, melainkan karena keduanya berasal dari foto lain sedangkan penyapuan setelah penamaan dibatasi pada opname yang sama. Opname berikutnya akan mengenalinya karena galeri sudah diperkaya.

Yang tidak kami ukur, dan itu kesalahan prosedur, bukan keterbatasan sistem. Tidak ada hitungan manual sebagai pembanding, sehingga akurasi hitungan tidak dapat dinyatakan sebagai angka. Kesan di lokasi adalah barang kecil pada rak padat terlewat, tetapi kesan bukan pengukuran, dan kami tidak menuliskannya sebagai temuan. Uji berikutnya menghitung satu rak secara manual lebih dulu.

Jalur perbaikan-diri di \$4.5 terpakai dua kali di lokasi dan berakhir berbeda sesuai rancangan: pada opname yang belum dibukukan hitungannya berpindah ke produk yang baru dinamai, sedangkan pada opname yang sudah dibukukan galerinya tetap diperkaya tetapi hitungan lamanya tidak diubah, karena laporan yang sudah masuk buku stok tidak boleh berubah di belakang punggung pemiliknya.

7. Kesimpulan

StokLens menjawab persoalan yang nyata dan terukur: pemilik warung tidak mengetahui nilai stok dan angka kehilangannya karena menghitung manual terlalu mahal. Pendekatan yang dipilih (deteksi produk pada foto rak, pengenalan berbasis pembandingan embedding tanpa retraining, dan pelaporan selisih dalam rupiah) memungkinkan opname dilakukan dengan perangkat yang sudah dimiliki pemilik warung.

Tiga hal yang kami anggap paling menentukan:

1. **Berjalan lokal sepenuhnya.** Biaya per-scan nol dan data tidak pernah keluar dari toko, pembeda terhadap solusi yang bergantung pada layanan AI berbayar.
2. **Memperbaiki diri dari pemakaian.** Setiap barang yang gagal dikenali lalu diberi nama pengguna memperkaya galeri dalam kondisi yang identik dengan kondisi pemakaian nyata.
3. **Keputusan berbasis analisis, termasuk yang dikoreksi.** Beberapa keputusan penting justru merupakan pembatalan rencana awal setelah analisis menunjukkan rencana itu keliru: pembacaan tanggal kedaluwarsa yang dicabut setelah menemukan 0 dari 64, panduan pelabelan internal yang dikoreksi setelah ditemukan merusak 20% anotasi tanpa memunculkan galat, dan ambang pencocokan yang dinaikkan berdasarkan pengukuran lalu diturunkan lagi ketika pengukuran kedua memakai data yang lebih benar.

Fine-tune dua tahap sudah selesai dan terukur pada warung yang seluruhnya ditahan dari data latih:

mAP50 0,304 → 0,827 dan **recall 0,279 → 0,787**. Recall adalah angka yang membatasi akurasi opname, karena barang yang tidak terdeteksi tidak akan pernah terhitung.

Uji lapangan pertama dilaporkan apa adanya di \$6.1, termasuk bagian yang gagal dan satu pengukuran yang luput kami ambil. Arahnya jelas: yang membatasi sekarang bukan arsitektur atau ambang, melainkan jumlah produk terdaftar dan keragaman data latih pada rak padat. Pengumpulan gelombang berikutnya sedang berjalan, dan pengujian berikutnya menyertakan hitungan manual sebagai pembanding sehingga akurasi dapat dinyatakan sebagai angka, bukan kesan.

Daftar Pustaka

[1] Niaga.Asia, "Jumlah Toko Kelontong 3,94 Juta, Mendag: Setara 98,78 Persen Ritel", 11 November 2024, mengutip data Euromonitor 2022. <https://www.niaga.asia/jumlah-toko-kelontong-394-juta-mendag-setara-9878-persen-ritel/>

[2] Bisnis Daily, "Jumlah Warung Kelontong Terus Menyusut, APKLI: Tersisa 3,9 Juta Unit", 27 Februari 2026, mengutip Asosiasi Pedagang Kaki Lima Indonesia. <https://bisnisdaily.com/read/serba-serbi-umkm/jumlah-warung-kelontong-terus-menyusut-apkli-tersisa-39-juta-unit>

[3] National Retail Federation, "National Retail Security Survey 2023", 26 September 2023. Rata-rata *shrink rate* FY2022 sebesar 1,6% dari penjualan, setara 112,1 miliar dolar AS. <https://nrf.com/research/national-retail-security-survey-2023>

[4] OCBC dan NielsenIQ, "Business Fitness Index 2024", dilaporkan Suara.com, 26 November 2025. <https://www.suara.com/bisnis/2025/11/26/074526/riset-77-persen-umkm-masih-lakukan-pencatatan-keuangan-secara-manual>

Catatan: rujukan [3] berasal dari ritel modern Amerika Serikat dan **tidak** dipakai sebagai estimasi kehilangan di warung Indonesia. Angka itu dikutip untuk menunjukkan bahwa besaran seperti itu hanya diketahui bila ada yang menghitung, dan warung tidak memilikinya.

Lampiran A: Ringkasan Keputusan Teknis

#	Keputusan	Alasan singkat
1	SQLite satu berkas	Skala warung; satu perintah jalan; cadangan = salin berkas
2	CLIP zero-shot, bukan pengklasifikasi terlatih	Barang baru tidak boleh memerlukan retraining
3	Satu kelas produk pada detektor	Pelabelan cepat; barang baru tidak perlu pelabelan ulang
4	Mode foto sebagai mode utama	Satu deteksi = satu barang; lebih murah; tanpa blur gerakan
5	Anti dobel-hitung berlapis tiga	Tidak ada satu mekanisme yang cukup
6	Galeri banyak-vektor, bukan rata-rata	Rata-rata dua kondisi berbeda tidak mirip keduanya
7	Vektor dihitung saat scan	Endpoint pemberian nama bebas CLIP, cepat, dapat diuji
8	Ledger, bukan kolom angka	Selisih tidak bermakna tanpa pembandingan yang tertelusur
9	Pre-train dua tahap	Dataset sendiri terlalu kecil untuk bentuk umum rak
10	Foto dataset dari warung, bukan grosir	Menghindari jurang domain kedua
11	Satu sachet = satu kotak pada renceng	Menyamakan dengan cara warung menghitung stok
12	Menolak scraping marketplace	Melanggar ketentuan layanan dan jenis datanya salah